

不等式

• Markov 不等式 对 r.v. X 和 $\varepsilon > 0$, 有 $P(X \geq \varepsilon) \leq \frac{E|X|^\alpha}{\varepsilon^\alpha}$, $\alpha > 0$.

(证明) $P(|X| \geq \varepsilon) = E[1_{(|X|^\alpha) \geq \varepsilon^\alpha}] \leq E\left[\left(\frac{|X|^\alpha}{\varepsilon^\alpha}\right)\right] \leq E\left(\frac{|X|^\alpha}{\varepsilon^\alpha}\right) = \frac{E|X|^\alpha}{\varepsilon^\alpha}$, $\alpha > 0$.

Chebyshov 不等式 $P(|X - EX| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}$.

• 内积不等式 EX^2 和 $EY^2 < \infty$, 则 $|E(XY)| \leq \sqrt{EX^2EY^2}$. 等号成立 $\Leftrightarrow \exists a, b \text{ 不全为 } 0, aX + bY = 0_a.s.$

(31) 具体代入 $\langle \vec{a}, \vec{b} \rangle = \vec{a} \cdot \vec{b}$, $\langle X, Y \rangle \triangleq E(XY)$, $|XY| = \langle X, Y \rangle = EX^2$.

$$E|XY| \leq \sqrt{EX^2EY^2}, |\vec{a} \cdot \vec{b}| \leq \sqrt{|\vec{a}|^2|\vec{b}|^2}, |\vec{a}| |\vec{b}| \cos \theta \leq |\vec{a}| |\vec{b}|.$$

• Jensen 不等式 (Jensen's inequality)

φ 是 \mathbb{R} 上的凸函数 (convex), X 和 $\varphi(X)$ 都有有限的期望, 则有

$\varphi(EX) \leq E(\varphi(X))$. 对严格凸的 φ , 等号成立当且仅当 $X = EX$. a.s.

证明: 凸函数 \rightarrow 对任意 a, b 都存在一常数 c , 使得

$\varphi(b) - \varphi(a) \geq c(b-a)$. 令 $a = EX$, $b = X$, 则有 $\varphi(X) - \varphi(EX) \geq c(X - EX)$.

两侧求期望得 $E(\varphi(X)) - \varphi(EX) \geq cE(X - EX) = 0$.

应用: EM 算法 (Expectation-Maximization algorithm); 证明 MLE (maximum likelihood estimator) 的一致估计性.

条件期望、条件方差

期望 (离散) 若 $\sum_i |X_i| P(X=X_i|A) < \infty$, 则 $E(X|A) = \sum_i X_i P(X=X_i|A)$.

(连续) 若 $\int_{-\infty}^{\infty} |x| f_{X|A}(x|A) dx < \infty$, 则 $E(X|A) = \int_{-\infty}^{\infty} x f_{X|A}(x|A) dx$.

条件期望的3种理解 (具体解释见下页)

代数定义 (平均值) 几何 (投影) 选择最优化方案 (预测)

例 灯泡已工作 a 天, 寿命 $X \sim \mathcal{E}(\lambda)$, 求现在寿命的期望 ($\bar{X}+a$)

$$E(X|X \geq a) = \int_a^{+\infty} x f(x|X \geq a) dx. \text{ 其中 } f(x|X \geq a) = \frac{\lambda e^{-\lambda x}}{e^{-\lambda a}} = \lambda e^{\lambda(a-x)}$$

$$E(X|X \geq a) = \int_a^{+\infty} \lambda e^{\lambda a} \cdot (\lambda e^{-\lambda x}) dx = \bar{X} + a.$$

灯泡 $X \sim \mathcal{E}(\lambda)$, $Y \sim \mathcal{E}(\mu)$ 且相互独立, X 寿命短于 Y , 求 $E(X|X < Y)$.

$$E(X|X < Y) = \frac{E(X|X < Y)}{P(X < Y)} = \frac{\int_0^{\infty} x f(x) dx / 3}{\int_0^{\infty} f(x) dx / \int_x^{\infty} f(y) dy}, Z = X|X < Y, f(z) = \lambda e^{-(\lambda+\mu)z}$$

$$E(X|X < Y) = \frac{\lambda}{\lambda+\mu} = \frac{1}{\lambda+\mu}.$$

定理 若 $P(A)$ 是非负随机变量, 则 $E(X|A) = \frac{E(XA)}{P(A)}$.

证明 $E(X|A)$ 是在 $P_A(\cdot) = P(\cdot|A)$ 下对 X 求期望, 则 $E(X|A) = \int_0^\infty P(X>x|A) dx$

$$E(X|A) = \frac{1}{P(A)} \int_0^\infty P(X>x \cap A) dx = \frac{1}{P(A)} \int_0^\infty P(X|A>x) dx = \frac{E(X_A)}{P(A)}.$$

条件期望转化为无条件期望 + 事件概率组合操作.

定理 (全期望定理) (全概率公式而变形)

设 $A_1 \dots A_n$ 构成 Ω 的一个分割. $E(X) = \sum_{i=1}^n P(A_i) E(X|A_i)$.

例 连续抛掷一枚均匀硬币, 分别记 W_{HT} , W_{HH} 为等到第一个 HT , HH 的抛掷次数. 求 $E(W_{HT})$ 和 $E(W_{HH})$. (4,6)

背景: $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 给定 $Y=y$ 时 $X|Y=y \sim N(\mu_1 + \frac{\rho\sigma_1}{\sigma_2}(y-\mu_2), (1-\rho^2)\sigma_1^2)$.

于是 $E(X|Y=y) = \mu_1 + \frac{\rho\sigma_1}{\sigma_2}(y-\mu_2)$, 从而 $E(X|Y) = \mu_1 + \frac{\rho\sigma_1}{\sigma_2}(Y-\mu_2)$.

在二元正态分布情况下恰能实现最优线性拟合.

$E(X|Y)$ 定义: (X, Y) 为随机向量, $E(X) < \infty$, 若 $m(Y) = E(X|Y=y)$, 则称随机变量 $m(Y)$ 为给定 Y 对 X 的条件期望, 记为 $E(X|Y)$.

(离散型) 若 $\exists i$ 使 $P(X=x_i|Y=y) < \infty$, 则 $E(X|Y=y) = \sum_{x_i} x_i P(X=x_i|Y=y)$.

(连续型) 若 $\int_{-\infty}^{\infty} x f_{x|y}(x|y) dx < \infty$, 则 $E(X|Y=y) = \int_{-\infty}^{\infty} x f_{x|y}(x|y) dx$.

考虑 $E(X+Y|X)=m(X)$, 其中 $EY=\lambda$. $m(x)=E(X+Y|X=x)=E(Y|X=x)+x$

$m(x)=E(X+Y)$ (令 $A=\{X=x\}$). X, Y 独立, 则 $m(x)=x+\lambda$.

说明: $m(Y)$ 实际上是一个随 Y 变化的随机变量.

例. 设 X, Y 独立同分布, $X \sim P(\lambda)$, 求 $E(X+Y|X)$ 和 $E(X|X+Y)$. $\Rightarrow E(X|X+Y) = \frac{n}{2}$.

$\cup EAX = \sum k P_A(k)$, $P_A(k) = P(X=k|X+Y=n)$.

$\Rightarrow X|X+Y=n \sim B(n, \frac{1}{2})$, $X, Y \sim P(\lambda)$, $\frac{X+Y}{2}$ 也为 r.v.

$\Rightarrow E(X+Y|X+Y=n) = n = E(X|X+Y=n) + E(Y|X+Y=n) = 2E(X|X+Y=n)$.

那么 $E(X+Y|X) \sim P(\lambda)$, $E(X|X+Y) \sim B(X+Y, \frac{1}{2})$.

统计学中的线性回归模型即基于条件期望思想. 希望用条件期望 \rightarrow 期望

(定理) 重期望法则: X, Y 为随机变量, $E(E(X|Y)) = EX$.

(证明) $E(E(X|Y)) = E(m(Y)) = \sum_y m(y) P_Y(y) = \sum_y E(X|Y=y) P_Y(y)$ (接下页)
(以离散为例)

$$= \sum_{y \in Y} \sum_{x \in X} x P_{X|Y}(x|y) P_{Y|Y} = \sum_x \sum_y P_{X|Y}(x|y) P_{Y|Y} = \sum_x P(x) = E(X).$$

常时有层次结构有简化作用, 如 Bayes 网络.

条件期望的性质 (X, Y 为 r.v., $g(x), h(y)$ 为实函数, $E(X) < \infty, E(g(x)) < \infty$)

$$1^{\circ} |E(X|Y)| \leq E(|X| | Y). \quad (E(|X| \geq |EX|))$$

$$2^{\circ} [E(X|Y)]^2 \leq E(X^2 | Y).$$

$$3^{\circ} E[h(Y)g(X)|Y] = h(Y)E[g(X|Y)]$$

$$4^{\circ} E[Eg(X|Y)] = Eg(X).$$

$$5^{\circ} \text{当 } X, Y \text{ 独立时 } E[g(X|Y)] = Eg(X);$$

$$6^{\circ} \text{r.v. } X_1, \dots, X_n \text{ 的期望有限, } E(C + \sum_{i=1}^n c_i X_i | Y) = C + \sum_{i=1}^n c_i E(X_i | Y).$$

$$7^{\circ} \text{若 } X_1 \leq X_2, \text{ 则 } E(X_1 | Y) \leq E(X_2 | Y).$$

例 X, Y 为随机变量, $h(x)$ 是实函数, 若 $EX^2 < \infty, Eh^2(Y) < \infty$, 则

$$E[(X - E(X|Y))h(Y)] = 0.$$

证明: 由 Cauchy-Schwarz 不等式可得 $E(|Xh(Y)|) \leq \sqrt{EX^2 Eh^2(Y)} < \infty$.

$$\text{利用条件期望性质, } E((X - E(X|Y))h(Y)) = E(Xh(Y)) - E(E(X|Y)h(Y)).$$

$$= E(Xh(Y)) - E(E(Xh(Y)|Y)) = E(Xh(Y)) - E(Xh(Y)) = 0.$$

• 最佳预测性质: 设 $EX^2 < \infty, m(Y) = E(X|Y)$, 则对任意实函数 $g(Y)$ 有

$$E(X - m(Y))^2 \leq E(X - g(Y))^2. \text{ 等号成立当且仅当 } g(Y) = m(Y) \text{ 且 } Eh^2(Y) < \infty.$$

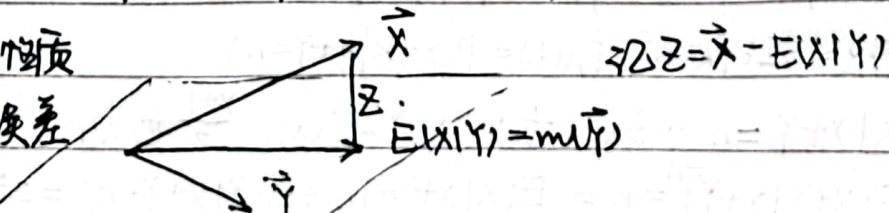
(证明) $E(g(Y))^2 < \infty$ 时一定成立. 否则: 首先 $E^2(X|Y) \leq E(X^2|Y)$, 从而 $E(m(Y))^2 \leq EX^2$.

$$\text{令 } h(Y) = m(Y) - g(Y), \text{ 则 } E(X - g(Y))^2 = E(X - m(Y) + m(Y) - g(Y))^2 = E(X - m(Y))^2 + E(m(Y) - g(Y))^2 \\ + 2E(X - m(Y)m(Y) - g(Y)) = E(X - m(Y))^2 + E(m(Y) - g(Y))^2 \geq E(X - m(Y))^2.$$

• 图形理解: $E(X|Y)$ 的概念

可以证明 $E(X|Y)$ 是均方误差

意义下的最优预测.



$E(X|Y)$ 的意义: 对正态分布而言 $E(X|Y) = \mu_1 + \frac{\rho \sigma_1}{\sigma_2} (Y - \mu_2)$, 最佳预测 = 最佳线性预测

说明: 证明前必须指出 EX^2 有限.

等号成立当且仅当 $E[m(Y) - g(Y)]^2 = 0$, 当且仅当 $g(Y) = m(Y)$ 且 $Evar(X) \leq E(X - c)^2$.

称 $m(Y) = E(X|Y)$ 是 X 的最佳预测 (optimal forecast)

若 $E(X|Y)=C$, X, Y 不是独立: 例如为 $X+Y \leq 1$ 均匀分布.

Date: 3/1

(定义) 若 $E((X-E(X|Y))^2|Y)$ 存在, 称其为给定 Y 下 X 的条件方差, 即

$$\text{var}(X|Y) = E\{(X-E(X|Y))^2|Y\}.$$

(原理) 全方差法则: $\text{var}(X) = E(\text{var}(X|Y)) + \text{var}(E(X|Y))$

$$\begin{aligned} \text{证明: } \text{var}(X) &= E(X-\bar{X})^2 = E\{[X-E(X|Y)+E(X|Y)]-E(X-E(X|Y)+E(X|Y))\}^2 \\ &= E(X-E(X|Y))^2 + \text{var}(E(X|Y)) = E(E\{(X-E(X|Y))^2|Y\}) + \text{var}(E(X|Y)) = E(\text{var}(X|Y)) + \end{aligned}$$

例 论文数据问题

TIPS: 条件在随机变量上时, 先用 $X=x$ 赋值计算, 再将结果中常数换为随机变量 X .

利用对称性; 求和/积分换序等价.

二次型期望运算中用加减项 很符合常数均值随机变量.

协方差与相关

(定义) 设 EX 和 EY 存在, 当 $E|(X-EX)(Y-EY)| < \infty$ 时, 称

$\text{cov}(X, Y) = E[(X-EX)(Y-EY)]$ 为 X, Y 的协方差 (covariance).

$\text{cov} > 0 \Rightarrow$ 正相关, $\text{cov} = 0 \Rightarrow$ 不相关, $\text{cov} < 0 \Rightarrow$ 负相关.

性质

$$1^\circ \text{cov}(X, X) = \text{var}(X)$$

$$2^\circ \text{cov}(X, Y) = \text{cov}(Y, X)$$

$$3^\circ \text{cov}(X, Y) = E(XY) - EX \cdot EY \quad (\text{常用计算公式})$$

$$4^\circ \text{若 } C \text{ 为某常数, 则 } \text{cov}(X, C) = 0.$$

$$5^\circ (\text{双线性}) \text{cov}(CX, Y) = C\text{cov}(X, Y), \text{cov}(X, Y+Z) = \text{cov}(X, Y) + \text{cov}(X, Z)$$

$$6^\circ \text{var}(X_1+X_2) = \text{var}(X_1) + \text{var}(X_2) + 2\text{cov}(X_1, X_2).$$

$$(\Rightarrow \text{var}(X_1+\dots+X_n) = \sum_{i=1}^n \text{var}(X_i) + \sum_{1 \leq i < j} \text{cov}(X_i, X_j) = \sum_{i=1}^n \text{var}(X_i) + 2 \sum_{1 < i < j} \text{cov}(X_i, X_j))$$

例 多项分布: 经典离散型随机向量例

同学例来自 r 个年级, 两课堂随机点名 (有放回), 记 A_i 表示点到第 i 行
由此 $EXY = EXEY$ 不能推出 X, Y 独立, 因为它刻画了线性关联.

deci 得力

年级的同学。一堂课计划点名 n 次，用 X_i 表示 A_i 发生次数。 $\forall i$

(X_1, \dots, X_n) 的概率分布是 $P(X_1=k_1, \dots, X_n=k_n) = \frac{n!}{k_1! \dots k_n!} p_1^{k_1} \dots p_n^{k_n}$.

(其中 $k_i \geq 0$, $p_i = P(A_i)$, $\sum_{i=1}^n k_i = n$)

$X_i \sim B(n, p_i)$, $\text{var}(X_i) = np_i(1-p_i)$; 先考虑 12 项

$$\text{cov}(X_1, X_2) \Rightarrow \text{var}(X_1 + X_2) = \text{var}(X_1) + \text{var}(X_2) - 2\text{cov}(X_1, X_2). X_1 + X_2 \sim B(n, p_1 + p_2)$$

或者用示性函数表示: $X_1 = J_1 + J_2 + \dots + J_n$, $X_2 = J_1 + \dots + J_n$. $J_i \sim B(p_i)$

$$\text{cov}(\sum J_i, \sum J_j) = \sum \sum \text{cov}(J_i, J_j) = \sum \sum (E(J_i J_j) - E J_i E J_j)$$

有效回抽取相互独立, 且 $J_i J_j$ 在 $i=j$ 时一定为 0.

$$\text{cov}(\sum J_i, \sum J_j) = \sum_{i=1}^n E J_i J_j + \sum_{i \neq j} E J_i J_j \stackrel{i \neq j}{=} \sum_{i \neq j} E J_i E J_j = 0 + n(n-1)p_1 p_2 - n^2 p_1 p_2 = -np_1 p_2.$$

说明: 协方差的符号表示相关趋势, 但大小不具有可比性(随单位变化)

(定义) $0 < \text{var}(X)\text{var}(Y) < \infty$ 时称 $\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$ 为

X, Y 的相关系数 (Pearson's correlation), $\xrightarrow{\text{若 } X, Y \text{ 标准化}}$

以二项正态分布为例 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho) \Rightarrow \text{corr}(X, Y) = \rho$.

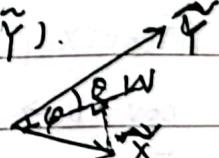
一般记作符号 P_{XY} . 相关系数具有可比性. 且 X, Y 独立 $\Leftrightarrow X, Y$ 不相关.

定理 $|P_{XY}| \leq 1$. $|P_{XY}| = 1 \Leftrightarrow$ 存在常数 a, b, c 使得 $ax + by = c$. a.s. $\Leftrightarrow X, Y$ 线性

(深入理解) 定理: X, Y 相互独立, 则 X, Y 不相关, 即 $\text{cov}(X, Y) = 0$.

考虑 $\tilde{X} = X - EX$, $\tilde{Y} = Y - EY$. 则 $E\tilde{X} = 0$, $E\tilde{Y} = 0$. $\text{corr}(X, Y) = \text{corr}(\tilde{X}, \tilde{Y})$.

几何解释: $\langle \tilde{X}, \tilde{Y} \rangle \triangleq E(\tilde{X}\tilde{Y}) \Leftrightarrow \langle \tilde{a}, \tilde{b} \rangle \triangleq \tilde{a} \cdot \tilde{b}$.



只有当二元正态分布时才相关 \Leftrightarrow 独立.

也就是说, X, Y 可能不相互独立, 但 (比如垂直时) 相关系数为 0 \Rightarrow 没有线性关系.

经典反例: X, Y 在单位圆 $x^2 + y^2 = 1$ 内均匀分布, 则 X, Y 不相关也不独立.

归纳说明: 不独立 \rightarrow 线性关联 (ρ) 或非线性关联. 独立 \rightarrow 不相关.

几何补充: 令 $W = E(\tilde{X}|\tilde{Y}) = m(\tilde{Y})$, 它是 X 在 Y 所在平面上的投影.

$$\text{corr}(X, Y) = \frac{\langle X, Y \rangle}{\|X\| \|Y\|} = \frac{\langle W, Y \rangle}{\|W\| \|Y\|} = \frac{|W|}{\|X\|} \text{ a.s. } \|X\| \text{ 或 } \|\tilde{Y}\| = 0 \text{ 时 corr 不存在}$$

例: (X, Y) 服从二元正态分布, 当 $E(X|Y) = \mu$ (const). X, Y 独立. 因为 $E(X) = E(E(X|Y)) = \mu$.

$$\text{且 } E(X-\mu|Y) = E(E(X-\mu|Y)|Y) = E[Y(E(X-\mu|Y)-\mu)] = E[Y \cdot 0] = 0. \text{ cov}(X, Y) = 0.$$

二元正态分布下, 独立 \Leftrightarrow 不相关.

概率母函数、矩母函数、特征母函数

(定义) 设 X 是取非负整值的随机向量, 称 $g(s) = E(s^X) = \sum_{j=0}^{\infty} s^j P(X=j)$, $s \in [-1, 1]$.

为 X 的概率母函数 (probability-generating function). 约定 $0^0 = 1$.

背景: X_1, \dots, X_n 独立同分布, 且 $\sim U(-1, 1)$. 则 $S_n = X_1 + \dots + X_n$ 的密度函数为
 $f_{S_n}(x) = \frac{1}{2^n n!} \prod_{k=0}^{n-1} \binom{n+k}{k} (n+k-x)_+^{n-k}$, $|x| \leq n$. (之前用卷积推)

虽然, 概率母函数 $g(s)$ 在 $[-1, 1]$ 上绝对收敛.

性质: $g(s)$ 为 X 的 pgf, $g^{(k)}(s)$ 是其 k 阶导数. 则 $P(X=k) = \frac{g^{(k)}(1)}{k!}$, $k=0, 1, \dots$

(证明: 概率母函数与概率分布列相互唯一确定)

$$\frac{g^{(k)}(0)}{k!} = \frac{g^{(k)}(s)}{k!} \Big|_{s=0} = \frac{1}{k!} \sum_{j=k}^{\infty} \frac{d^k}{ds^k} g(s_j) P(X=j) \Big|_{s=0} = P(X=k).$$

2° $E(X) = g^{(1)}(1)$. 因为 $g^{(1)}(1) = \sum_{j=0}^{\infty} j P(X=j) = EX$.

3° 若 $EX < \infty$, 则 $\text{var } X = g^{(2)}(1) + g^{(1)}(1)^2 - [g^{(1)}(1)]^2$.

$$(证) g^{(2)}(1) + g^{(1)}(1)^2 - [g^{(1)}(1)]^2 = \sum_{j=0}^{\infty} j(j-1)P(X=j) + \sum_{j=0}^{\infty} j P(X=j) - E^2 X = E(X(X-1)) + EX - E^2 X = \text{var}(X).$$

4° 若 X_1, \dots, X_n 相互独立, $g_i(s) = E(s^{X_i})$ 是 X_i 的概率母函数, 则

$$Y = X_1 + \dots + X_n$$
 的 pgf 为 $g_Y(s) = g_1(s) g_2(s) \dots g_n(s)$, $s \in [-1, 1]$.

理解: pgf 可以一次性处理多个随机变量, 无需再用归纳法划分为 2 个分组处理.

· 二项分布 $B(n, p)$ 的 pgf: $g(s) = \sum_{j=0}^n s^j \binom{n}{j} p^j q^{n-j} = (qs+p)^n$.

设 X_1, \dots, X_m 相互独立且 $X_i \sim B(n_i, p_i)$, 则 $X_1 + X_2 + \dots + X_m \sim B(n_1 + n_2 + \dots + n_m, p)$.

· 泊松分布 $P(\lambda)$ pgf $\Rightarrow g(s) = \sum_{k=0}^{\infty} s^k \frac{\lambda^k}{k!} e^{-\lambda} = e^{\lambda(s-1)}$.

设 X_1, \dots, X_m 相互独立且 $X_i \sim P(\lambda_i)$, 则 $X_1 + X_2 + \dots + X_m \sim P(\lambda_1 + \dots + \lambda_m)$.

· 几何分布 $G(p)$: $g(s) = \sum_{k=1}^{\infty} s^k p q^{k-1} = \frac{sp}{1-sq}$.

设 X_1, X_2, \dots, X_m 相互独立且 $X_i \sim G(p)$. 则 $S_m = \sum X_i$, pgf: $g_m(s) = \left(\frac{sp}{1-sq}\right)^m$.

对其进行 Taylor 展开: $g_m(s) = (sp)^m \sum_{j=0}^m \frac{(m+j)!}{j!} (sq)^j = \sum_{k=m}^{\infty} \binom{k-1}{m-1} p^m q^{k-m} s^k$

于是得到 Pascal 分布 $P(S_m=k) = \binom{k-1}{m-1} p^m q^{k-m}$, $k=m, m+1, \dots$

pgf 本质上是同 colp 的函数, $g(s) = Es^X = p_0 s^0 + p_1 s^1 + p_2 s^2 + \dots$ (由 p_i 构成 PMF)

$$\text{已知 } g(s, t) = E(s^X t^Y).$$

$$g_X(s) \Rightarrow g_{X_1 + \dots + X_n} \begin{cases} \text{已知} \\ \text{未知} \end{cases}$$

置变量易于指数, 对 iid 可直接拆开.

(仍待求导) PMF Taylor 展开, 直接读函数

函数可以直接处理 iid $X_1 + \dots + X_n$ 问题, 取代卷积. deli 得力

Date.

(随机变量个随机变量之和)

设 $\{X_i\}$ 是一列独立同分布的非负整值随机变量, 且 X_1 的 pgf 为

$$g(s) = \sum_{k=0}^{\infty} P_k s^k, \quad P_k = \mathbb{P}(X_1 = k)$$

2) N 为正整数随机变量, 且其 pgf $G(s) = \sum_{n=1}^{\infty} s^n \mathbb{P}(N=n)$.3) N 与 $\{X_i\}$ 相互独立.则 $W \triangleq X_1 + X_2 + \dots + X_N$ 的概率母函数 $H(s) = G(g(s))$ 例 X_1, \dots, X_n 独立同分布, $X_i \sim G(p)$, $N \sim (\bar{p})$ 且与全部 X_i 独立, 求 $S_N = X_1 + \dots + X_N$.n何分布的概率母函数 $g(s) = \sum_{k=0}^{\infty} s^k p q^{k-1} = \frac{sp}{1-sq}$. $g_N(s) = \frac{sp}{1-sq}$.代入 $H(s) = G(g(s)) = \frac{spp}{1-s(q+pq)} = \frac{spp}{1-s(1-p)}$, 由可逆性可知 S_N 也是 n何分布. $S_N \sim G(p)$.

(有限个 n何分布之和不是 n何分布, 但 n何分布个 n何分布和仍为 n何分布)

(定义) (2维 pgf) 设 (X, Y) 是二维取非负整数值的随机向量, 其分布列 $P_{ik} = \mathbb{P}(X=i, Y=k)$,称 $g(s, t) = E[s^X t^Y] = \sum_{i=0}^{\infty} \sum_{k=0}^{\infty} P_{ik} s^i t^k$, $s, t \in [-1, 1]$ 为 X, Y 的概率母函数.性质 设 $g(s, t)$ 是 (X, Y) 的概率母函数, 则

$$1^\circ |g(s, t)| \leq g(1, 1) = 1, |s| \leq 1, |t| \leq 1.$$

$$2^\circ g_{ax+by+c}(s) = s^a g(s^a, s^b), a, b, c \text{ 均为常数}$$

$$3^\circ X \text{ 与 } Y \text{ 独立} \Leftrightarrow g(s, t) = g_X(s) g_Y(t), \forall s, t;$$

$$4^\circ g(s, 1) = g_X(s), g(1, t) = g_Y(t). \quad (\text{有一个变量为 1} \rightarrow \text{单变量分布})$$

$$5^\circ P_{ik} = \frac{1}{i! k!} \left. \frac{\partial^{i+k} g(s, t)}{\partial s^i \partial t^k} \right|_{s=t=0}, i, k=0, 1, 2, \dots$$

$$6^\circ \text{若 } EX, EY < \infty, \text{ 则 } EX = \left. \frac{\partial g(s, t)}{\partial s} \right|_{s=t=1}, EY = \left. \frac{\partial g(s, t)}{\partial t} \right|_{s=t=1}.$$

$$7^\circ \text{若 } EX^2, EY^2 < \infty, \text{ 则 } EX^2 = \left. \frac{\partial^2 g(s, t)}{\partial s^2} \right|_{s=t=1} + \left. \frac{\partial^2 g(s, t)}{\partial t^2} \right|_{s=t=1}, EY^2 = \left. \frac{\partial^2 g(s, t)}{\partial s^2} \right|_{s=t=1} + \left. \frac{\partial^2 g(s, t)}{\partial t^2} \right|_{s=t=1}, EXY = \left. \frac{\partial^2 g(s, t)}{\partial s \partial t} \right|_{s=t=1}.$$

矩母函数

(定义) X 为随机向量, 其矩母函数 (moment generating function) $M_X(s) = E(e^{sX})$.(理解) 利用 e^{sX} 的 Taylor 展开可以得到各阶矩 $EX^k = M_X^{(k)}(0)$.离散型: $M_X(s) = \sum_j e^{sx_j} \mathbb{P}(X=x_j)$ 连续型: $M_X(s) = \int_{-\infty}^{\infty} e^{sx} f(x) dx$ 仅当 $E(e^{sX}) < \infty$ 时我们认为 $M_X(s)$ 存在.

tips. Taylor 展开 $M(s)$, e^{is} 对应的原函数就是 $P(X=i)$.

性质 该 $M(s)$ 为 X 的矩母函数, $M^{(k)}(s)$ 为其 k 阶导数.

1° $Y = ax + b$ 的矩母函数为 $M_Y(s) = e^{sb} M(ax)$;

2° $EX^k = M^{(k)}(0)$, $k=1, 2, \dots$

3° $M(0) = 1$, 当 X 取非负整数值时 $P(X=0) = \lim_{s \rightarrow -\infty} M(s)$.

4° 可逆性: 若存在一正数 a , 使得对 $\forall s \in [-a, a]$ 有 $M(s) < \infty$, 则 $M(s)$ 唯一决定 X 的分布

5° 若 X_1, \dots, X_n 相互独立, $M_{X_i}(s) = E(e^{sX_i})$ 是 X_i 的矩母函数, 则

$Y = X_1 + \dots + X_n$ 的矩母函数为 $M_Y(s) = M_{X_1}(s) \cdots M_{X_n}(s)$.

• PF 与 MGF 的关系 (大部分 r.v.)
 PF 与 MGF 的关系 (部分整数型)
 $PF: (q+ps)^n$ $MGF: (pe^s+q)^n$ $PF: e^{\lambda(s-1)}$
 $MGF: e^{\lambda(e^s-1)}$

定义 $ES^X = ps + ps + \dots + ps$ $Ee^{sX} = \sum_{n=0}^{\infty} \frac{EX^n}{n!} s^n$ $MGF: (pe^s+q)^n$
 可逆性 $PGF \leftrightarrow PMF$ (混合分布) $MGF \leftrightarrow CDF$ (注意 s 到 e^s 的替换)

$ax+b$ $\prod_{i=1}^n s g_{X_i}(s)$ $e^{sb} M_X(sa)$ $X_1 + \dots + X_n (U) = \prod_{i=1}^n M_i(s) \Rightarrow \prod_{i=1}^n g_i(s)$.

$X_1 + \dots + X_n (id)$ $g_N(s) \xrightarrow{s \rightarrow g_X(s)}$ $M_N(s) \xrightarrow{s \rightarrow e^s} M_X(s)$ MGF 有 $EX^k = M^{(k)}(0)$.

(X, Y) $E(s^X, t^Y) = E(e^{sX}, e^{tY})$.

例 指数分布 $\Sigma(\lambda)$, $f(x) = \lambda e^{-\lambda x} I_{(x \geq 0)}$, 求矩母函数 $M(s)$, $EX = \text{平均矩 } EX^2$.

$s < \lambda$ 时有 $M(s) = \lambda \int_0^\infty e^{sx} e^{-\lambda x} dx = \lambda \frac{e^{(s-\lambda)x}}{s-\lambda} \Big|_0^\infty = \frac{\lambda}{\lambda-s}$. ($s \geq \lambda$ 时无意义)

$EX = M^{(1)}(0) = \lambda$, $EX^2 = M^{(2)}(0) = \frac{2}{\lambda^2}$.

例 (混合分布) 银行内 3 位交易员为顾客服务时间均服从指数分布. 两位 $\lambda=6$, 一位 $\lambda=4$.

随机选择一名交易员, 求接受服务时间 T 的矩母函数.

$f_T(t) = (\frac{2}{3} 6e^{-6t} + \frac{1}{3} 4e^{-4t})$, $t \geq 0$, $\frac{2}{3}$ 和 $\frac{1}{3}$ 表示概率混合而不是单次随机选择的时间分布.

$M_T(s) = \int_0^\infty e^{st} f_T(t) dt = \frac{2}{3} \frac{6}{6-s} + \frac{1}{3} \frac{4}{4-s} = \frac{2}{3} M(s)_{X_1} + \frac{1}{3} M(s)_{X_2}$.

反演: 若已知 X 的矩母函数形如 $p_1 M_{X_1}(s) + p_2 M_{X_2}(s)$, 则 X 是 X_1, X_2 的混合变量,

X_1, X_2 被选中概率分别为 p_1, p_2 , $f_X(x) = p_1 f_{X_1}(x) + p_2 f_{X_2}(x)$.

例 (正态分布) $Z = X + Y$, $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, 相互独立. 求 Z 的 pdf.

若 $V \sim N(0, 1)$, $M_V(s) = e^{\frac{s^2}{2}}$; 若 $W \sim N(\mu, \sigma^2)$, 由教材知 $M_W(s) = e^{\mu s + \frac{(\sigma^2 s^2)/2}{2}}$,

$\Rightarrow M_Z(s) = M_X(s)M_Y(s) = e^{(\mu_1+\mu_2)s + \frac{[(\sigma_1^2 + \sigma_2^2)s^2]/2}{2}}$, $Z \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

可见独立的正态分布函数之和依然为正态分布.

• 若 $X \sim N(0, 1)$, 则 $EX^n = \begin{cases} 0, & n \text{ 为奇数.} \\ \frac{n!}{2^{\frac{n}{2}} (\frac{n}{2})!}, & n \text{ 为偶数.} \end{cases}$ (相当于 $n!/2$ 双阶乘)

随机数个随机变量和的矩母函数

设 $\{X_i\}$ iid, 有共同矩母函数 $M_X(s)$, N 为取正整数值的随机变量, 且独立于 $\{X_i\}$. 令 $Y = \sum_{i=1}^N X_i$, $M_Y(s) = E[e^{sY}] = E(E[e^{sY}|N=n]) = E(M_X(s)^n) = \sum_{n=1}^{\infty} M_X(s)^n P(N=n)$.

($M_N(s) = \sum_{n=1}^{\infty} (e^s)^n P(N=n)$, 把 e^s 换成 $M_X(s)$. 相当于 pgf \rightarrow mgf $\xrightarrow{sY} M_Y(s)$).

例 $X_i \sim \Sigma(\lambda)$, $N \sim G(1-p)$. $M_N(s) = \frac{pe^s}{1-(1-p)e^s}$, $M_X(s) = \frac{\lambda}{\lambda-s}$.

$M_Y(s) = \frac{pM_X(s)}{1-(1-p)M_X(s)} = \frac{p\lambda}{p\lambda-s}$, 即 $Y \sim \Sigma(p\lambda)$. 若 $Y = X_1 + \dots + X_n$, $M_Y(s) = [M_X(s)]^n$.

随机向量 $\vec{X} = (X_1, \dots, X_n)$ 对应的多元矩母函数 $M_{\vec{X}}(\vec{s}) = E(e^{s_1 X_1 + \dots + s_n X_n})$.

特征函数

(定义) 对随机变量 X , 称 $\varphi(t) = E(e^{itX}) = E[\cos(tx) + i\sin(tx)]$, ($x \in \mathbb{R}$)

为 X 的特征函数 (characteristic function, CF), $i^2 = -1$.

性质 设 $\varphi(t) = E(e^{itX})$, 1° $|\varphi(t)| \leq |\varphi(0)| = 1$, $\varphi(-t) = \overline{\varphi(t)}$.

2° $\varphi(t)$ 在 $(-\infty, \infty)$ 上一致连续, 即 $|\varphi(t+h) - \varphi(t)| \leq E|e^{ht}|$.

3° 若 $E(|X|^k) < \infty$, 则 $\varphi^{(k)}(t) = i^k E(X^k e^{itX})$, $\varphi^{(k)}(0) = i^k E(X^k)$.

4° 对任意常数 a, b , 有 $\varphi_{aX+b}(t) = e^{itb} \varphi_a(at)$.

5° 若 X_k 有特征函数 $\varphi_k(t)$, 且 $\{X_k\}$ 相互独立, 则 $Y = X_1 + \dots + X_n$ 的

特征函数为 $\varphi_Y(t) = \prod_{k=1}^n \varphi_k(t)$.

(可以把 i 看成未知常量, 运算结束后再代入复数). 相似矩母函数: 特征函数一定存在.

· 二项分布 $B(n, p)$ $\varphi(t) = \sum_{j=0}^n e^{itj} \binom{n}{j} p^j q^{n-j} = (q + pe^{it})^n$.

· 泊松分布 $P(\lambda)$ $\varphi(t) = \sum_{k=0}^{\infty} e^{itk} \frac{\lambda^k}{k!} e^{-\lambda} = e^{\lambda(e^{it}-1)}$.

(对 $w =$ 矩母函数) pgf mgf cf (矩母函数, 一般用矩母函数)

$B(n, p)$	$(q+ps)^n$	$(q+pe^s)^n$	$(q+pe^{it})^n$
-----------	------------	--------------	-----------------

$P(\lambda)$	$e^{\lambda(s-1)}$	$e^{\lambda(s-1)}$	$e^{\lambda(e^{it}-1)}$
--------------	--------------------	--------------------	-------------------------

$G(1-p)$	$\frac{sp}{1-sq}$	$\frac{e^s p}{1-e^s q}$	$\frac{e^{it} p}{1-e^{it} q}$
----------	-------------------	-------------------------	-------------------------------

· 指数分布 $\Sigma(\lambda)$ $\varphi(t) = (1 - \frac{it}{\lambda})^{-1}$.

· 均匀分布 $U(a, b)$ $\varphi(t) = \frac{e^{itb} - e^{ita}}{it(b-a)}$, 特别地 $U(-c, c)$ 有 $\varphi(t) = \frac{\sin ct}{ct}$.

· 正态分布 $N(\mu, \sigma^2) \rightarrow \varphi(t) = \exp(i\mu t - \frac{1}{2}\sigma^2 t^2)$ $N(0, 1) \rightarrow \varphi(t) = e^{-\frac{1}{2}\sigma^2 t^2} = e^{-\frac{1}{2}t^2}$

(正态分布特征函数运算) 先考虑 $N(0,1)$: $\phi(t) = E[e^{itX}] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{itx} e^{-\frac{x^2}{2}} dx$
 $\phi(t) = e^{-\frac{t^2}{2}} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{(x-t)^2}{2}} dx = e^{-\frac{t^2}{2}}$ (积分内为正态分布)

或者 $\phi(t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \cos(tx) e^{-\frac{x^2}{2}} dx \Rightarrow \phi'(t) = -t\phi(t)$, $\phi(0) = 1 \Rightarrow \phi(t) = e^{-\frac{t^2}{2}}$.

对 $Y \sim N(\mu, \sigma^2)$: $X \sim N(0,1)$, $Y = \mu + \sigma X$. $E[e^{itY}] = e^{i\mu t} E[e^{it\sigma X}] = \exp[i\mu t - \frac{1}{2}\sigma^2 t^2]$.
 设 X_1, \dots, X_m 相互独立, $X_i \sim N(\mu_i, \sigma_i^2)$, 则 $Y = X_1 + \dots + X_m \sim N\left(\sum_{j=1}^m \mu_j, \sum_{j=1}^m \sigma_j^2\right)$.

- Cauchy 分布 $f(x) = \frac{1}{\pi(1+x^2)}$, $\phi(t) = e^{-|t|}$ 可直接使用, 有对应关系
- Laplace 分布 $f(x) = \frac{1}{2} e^{-|x|}$, $\phi(t) = \frac{1}{1+t^2}$.

特征函数一定存在且可逆为直观理解: 相当于将分布函数改变了坐标系.

随机变量的特征函数与分布函数相互唯一确定, 且均一定存在.

(反推) 逆转公式: 设 $\phi(t)$ 是 X 的特征函数, $F(x)$ 是 X 的分布函数, 若 $F(x)$ 在 (a, b) 连续, 则 $\frac{1}{2\pi} \lim_{T \rightarrow \infty} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \phi(it) dt = F(b) - F(a)$.

(反推) 若 X 的特征函数满足 $\int_{-\infty}^{\infty} |\phi(t)| dt < \infty$, 则 X 有连续密度函数 $f(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-itx} \phi(it) dt$.

(反推) 若 $E|X|^n < \infty$, 则 X 的特征函数 $\phi(t)$ 满足: $\phi(t) = \sum_{m=0}^n \frac{E[(tX)^m]}{m!} + o(t^n)$.

特别地, 若 $E(X^2) < \infty$, 则 $\phi(t) = 1 + itEX - \frac{1}{2}t^2 EX^2 + o(t^2)$.

(不一定存在, 如 Cauchy 分布) 如果各阶矩都存在, 由 Taylor 展开, 唯一确定了分布.

已知: $EXY = EXEY \Rightarrow X \perp\!\!\!\perp Y$, $E(X|Y) = C \Rightarrow X \perp\!\!\!\perp Y$. 和只看一阶矩相同, 只考虑 3 阶的独立性, 各阶矩都存在时才能唯一决定特征函数.

(反推) 混合分布: 若分布函数 $F_1(x), \dots, F_m(x)$ 的特征函数分别为 $\phi_1(t), \dots, \phi_m(t)$, $\lambda \geq 0$, 且 $\sum_{k=1}^m \lambda_k = 1$, 则 $\sum_{k=1}^m \lambda_k F_k$ 有特征函数 $\sum_{k=1}^m \lambda_k \phi_k(t)$.

注: $Y = \sum_{k=1}^m \lambda_k F_k$ 表示 Y 的概率 λ_k 等于 X_k (其分布为 F_k), 对 $\{X_m\}$ 之间的独立性无要求. 需要指出的是 $Y \neq \sum_{k=1}^m \lambda_k X_k$.

(定义) 设 $\vec{X} = (X_1, \dots, X_n)$ 为随机向量, \vec{X} 的特征函数定义为 $\psi(\vec{t}) = E(e^{i\vec{t} \cdot \vec{X}})$, $\vec{t} = (t_1, \dots, t_n)$.

(反推) $\vec{X} = (X_1, \dots, X_n)$ 为随机向量, X_1, \dots, X_n 相互独立的条件是 (充要条件)

$\psi(\vec{t}) = \psi_1(t_1)\psi_2(t_2)\dots\psi_n(t_n)$. $\psi_k(t_k)$ 是 X_k 的特征函数.

· 易错题: $\psi_{X+Y}(t) = \psi_X(t)\psi_Y(t)$, $t \in \mathbb{R}$, 能否说明 $X \perp\!\!\!\perp Y$. (不能)

反例: Cauchy 分布 $f(x) = \frac{1}{\pi(1+x^2)}$, $Y = aX$. $\phi_X(t) = e^{-|t|}$, $\phi_{X+Y}(t) = e^{-|t|} \cdot e^{-|at|} = \phi_X(t)\phi_Y(t)$.

理解: $\psi_{X+Y}(t)$ 只考虑了 $X = Y(t)$ 情况, 不够覆盖整个二维空间.

$$\frac{1}{n} \sum_{i=1}^n X_i = \text{样本均值}$$

大数定律

(弱律) (Weak law of large numbers, WLLN) 设 $\{X_n\}$ 是独立同分布的随机变量序列, 且 $\text{var}(X_1) < \infty$, 则对 $\forall \varepsilon > 0$, $\lim_{n \rightarrow \infty} P(|\frac{1}{n} \sum_{i=1}^n X_i - E(X_1)| \geq \varepsilon) = 0$.

也称 $\frac{1}{n} \sum_{k=1}^n X_k$ 依概率收敛到 $E(X_1)$, 即 $\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} E(X_1)$.

n 很大时有很大把握(但非 100%), 断言 $\frac{1}{n} \sum_{i=1}^n X_i$ 很接近 $E(X_1)$. (连接偶然性与必然性)
(证明) $\{X_n\}$ 独立同分布, $\text{var}(X_1) < \infty$. 要证: $\forall \varepsilon > 0$, $\lim_{n \rightarrow \infty} P(|\frac{1}{n} \sum_{i=1}^n X_i - E(X_1)| \geq \varepsilon) = 0$.

利用切比雪夫不等式: 对随机变量 X 和 $\varepsilon > 0$, $P(|X - E(X)| \geq \varepsilon) \leq \frac{\text{var}(X)}{\varepsilon^2}$. 由同分布,

$$* P(|\frac{1}{n} \sum_{i=1}^n X_i - E(X_1)| \geq \varepsilon) = P(|\frac{1}{n} \sum_{i=1}^n X_i - E(\frac{1}{n} \sum_{i=1}^n X_i)| \geq \varepsilon) \leq \frac{1}{\varepsilon^2} \text{var}(\frac{1}{n} \sum_{i=1}^n X_i),$$

$$\frac{1}{\varepsilon^2} \text{var}(\frac{1}{n} \sum_{i=1}^n X_i) = \frac{1}{n \varepsilon^2} \text{var}(X_1) \rightarrow 0, n \rightarrow \infty.$$

(定义) 若对 $\forall \varepsilon > 0$, 有 $\lim_{n \rightarrow \infty} P(|Y_n - Y| \geq \varepsilon) = 0$, 则称 Y_n 依概率收敛到 Y (convergence in probability), 记作 $Y_n \xrightarrow{P} Y$.

应用: (疫苗有效性问题) 设人群中疫苗有效的比例为 p . 随机抽 n 人, X_i 表示第 i 人有效. 样本中有效比例 $M_n = \frac{1}{n} \sum_{i=1}^n X_i$. 需抽多少人能保证误差大于 3% 的概率不超过 5%, 即 $P(|M_n - p| \geq 0.03) \leq 0.05$. 由上, $P(|M_n - p| \geq 0.03) \leq \frac{\text{var}(X_1)}{n \cdot 0.03^2} \leq 0.05$.

$\text{var}(X_1) = p(1-p) \leq \frac{1}{4}$. 故计算得取 $n=556$ 时可行.

放宽条件: <独立同分布(马尔可夫大数定律)> $\{X_n\}_{i=1}^n \xrightarrow{iid} \{X_n\}$ 同分布 \rightarrow 无约束

方差有限(辛钦大数定律) $\text{var}(X) < \infty \rightarrow E(X) < \infty \rightarrow n P(|X| \geq n) \rightarrow 0$

定理扩展 1 (Khinchin) $\{X_n\}$ 为 iid 且 $E(X_1) < \infty$, 则 $\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} E(X_1)$.

扩展 2 $\{X_n\}$ 是 iid 序列, 则存在实数列 $\{a_n\}$ 使得 $\frac{1}{n} \sum_{k=1}^n X_k - a_n \xrightarrow{P} 0$ 的充要条件是

$$n P(|X_1| \geq n) \rightarrow 0. \text{ 此时可取 } a_n = E(X_1 I_{|X_1| \geq n}).$$

· 强大数定律 (Strong law of large numbers, SLLN) 设 $\{X_n\}$ 是独立同分布的随机变量序列: 1° 若 $E(X_1) < \infty$, 则 $\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{a.s.} E(X_1)$, n 平处处收敛.

2° 反之, 若 $\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{a.s.} C$, 则 $E(X_1) < \infty$ 且 $C = E(X_1)$.

以上所述为充要条件. 几乎处处收敛 \rightarrow 概率 1 收敛, $P(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n X_k = E(X_1)) = 1$.

(定义) 若 $P(\lim_{n \rightarrow \infty} Y_n = Y) = 1$, 则称 Y_n 几乎处处收敛到 Y

(almost sure convergence), 记作 $Y_n \xrightarrow{a.s.} Y$ 或 $Y_n \rightarrow Y$ a.s.

$$\left\{ \lim_{n \rightarrow \infty} Y_n = Y \right\} = \left\{ \omega : \lim_{n \rightarrow \infty} Y_n(\omega) = Y(\omega) \right\} \rightarrow \bigcap_{n=1}^{\infty} \left\{ \omega : |Y_n(\omega) - Y(\omega)| < \varepsilon \right\} = \liminf_{n \rightarrow \infty} A_n \text{ (下极限)}$$

$$A_n = \{ |Y_n - Y| < \varepsilon \}.$$

n 处处收敛可以推出依概率收敛，即 $\lim_{n \rightarrow \infty} P(\lim_{n \rightarrow \infty} Y_n = Y) = 1 \Rightarrow \lim_{n \rightarrow \infty} P(|Y_n - Y| > \varepsilon) = 0$.

对 $\forall \varepsilon > 0$, 令 $A_n = \{w : |Y_n(w) - Y(w)| < \varepsilon\} = \{|Y_n - Y| < \varepsilon\}$.

则 $\lim_{n \rightarrow \infty} P(|Y_n - Y| > \varepsilon) = \lim_{n \rightarrow \infty} P(A_n^c) = \lim_{n \rightarrow \infty} (1 - P(A_n)) = 1 - \lim_{n \rightarrow \infty} P(A_n)$.

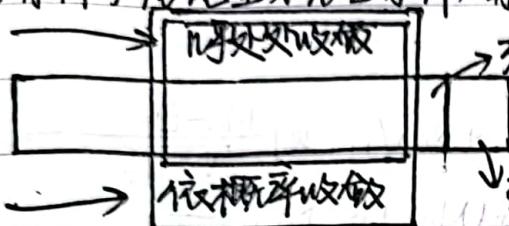
故 $\lim_{n \rightarrow \infty} P(|Y_n - Y| > \varepsilon) = 0 \Leftrightarrow$

(弱条件对应弱结论) $n P(X \geq n) \rightarrow 0 \Leftarrow E|X| < \infty$. (期望收敛是强弱条件)

因为 $E|X| = \sum_k k P(X=k) \Rightarrow \sum_k k P(k > k) \rightarrow 0 \geq \sum_n n P(|X| = n) = n P(|X| \geq n)$.

此等条件与结论互为充要条件, 条件强弱不同, 结论也强弱不同.

强大数



强: $E|X| < \infty$

直观: 样本次数越多, 样本均值
几乎一定渐近接近总体均值.

$\{X_n\}_{n=1}^{\infty}$

弱大数

弱: $n P(|X| \geq n) \rightarrow 0$

样本均值接近总体均值的
可能性越来越大

(反例) $\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k$ 服从弱大数定律, 但不服从强大数定律, 当 r.v. 序列 X ,

X_1, \dots, X_n 独立同分布, $P(X=m) = P(X=-m) = \frac{C}{2m \ln m}$, $m \geq 3$, C 为常数.

理解: 强大数定律的充要条件为 $\lim_{n \rightarrow \infty} n P(|X| \geq n) = 0$. 显然,

$$\lim_{n \rightarrow \infty} n P(|X| \geq n) = \lim_{n \rightarrow \infty} n \sum_{m=n}^{\infty} P(|X|=m).$$

· 经验分布 设 $\{X_j\}$ 是概率空间 (Ω, \mathcal{F}, P) 上 iid 随机序列, 用 x_j 表示 X_j 的观测值, 即对某个确定的 $w \in \Omega$, 有 $x_j = X_j(w)$. 则由概率论, $\{X_j\}$ 观测数据可以决定 X_j 的分布函数 $F(x)$.

(证明) 记 I_j 表示 $X_j \leq x$. $\{I_j\}$ 为 iid. $F(x) = P(X \leq x) = E I_j$. 考虑

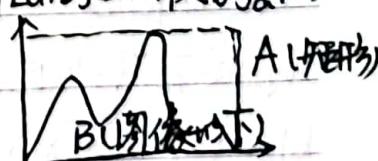
$$\frac{1}{n} \sum_{j=1}^n I_j \xrightarrow{a.s.} E I_j, \text{ 由大数定律, } \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{j=1}^n I_j = E I_j = E I_1 = P(X_1 \leq x) = F(x).$$

即由概率论, 有 $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{j=1}^n I_j = F(x)$. ($f_n(x) = \frac{1}{n} \sum_{j=1}^n I_j$)

· 例 Monte Carlo 蒙特卡洛方法: 估计某复杂有界函数 $f(x)$ 在区间 $[a, b]$ 上的积分 $\int_a^b f(x) dx$.

从 A 中随机抽取 n 个点 $(X_1, Y_1), \dots, (X_n, Y_n)$. I_j 表示 (X_j, Y_j) 在

B 中. 则由概率论有 $\frac{1}{n} \sum_{j=1}^n I_j \Rightarrow E I_j = P(I_j = 1) = \frac{\int_a^b f(x) dx}{c(b-a)}$.



那么 $\int_a^b f(x) dx \approx c(b-a) \frac{1}{n} \sum_{j=1}^n I_j$, 即可以用随机取样反映积分.

(随机模拟方法. 用随机反映必然性)

中心极限定理

(定理) Lindeberg - Lévy 中心极限定理

设 $\{X_n\}$ 是独立同分布的随机变量序列，其期望为 μ , 方差为 $\sigma^2 < \infty$,

$$\text{设 } S_n = X_1 + \dots + X_n, \text{ 则 } \frac{S_n - E(S_n)}{\sqrt{\text{Var}(S_n)}} \xrightarrow{d} N(0, 1).$$

注: $\forall x, F_{Y(x)}$ 连续, $\lim_{n \rightarrow \infty} F_n(x) = F_Y(x)$, 则 $\lim_{n \rightarrow \infty} F_n(x) \xrightarrow{d} F_Y(x), Y_n \xrightarrow{d} Y$. (依分布收敛)
(对每个 x 都收敛)

即 $Y_n \approx N(0, 1)$, $aY + b \approx N(b, a^2)$.

n 充分大时提供近似分布 $S_n \approx N(E(S_n), \text{Var}(S_n)) \approx N(n\mu, n\sigma^2)$.

直观解释: 大量独立同分布的随机因素.

· 定理变形: 样本均值解释. 设 $M_n = (X_1 + \dots + X_n)/n$, 则 $\frac{M_n - E(M_n)}{\sqrt{\text{Var}(M_n)}} \xrightarrow{d} N(0, 1)$.

n 充分大时提供近似分布 $M_n \approx N(E(M_n), \text{Var}(M_n)) \approx N(\mu, \frac{\sigma^2}{n})$.

(证明) 进行标准化, 令 $Y_k = \frac{X_k - \mu}{\sigma}$. $\{Y_k\}$ iid, $E(Y_k) = 0$, $\text{Var}(Y_k) = 1$, 要证: $\frac{1}{\sqrt{n}} \sum_{k=1}^n Y_k \xrightarrow{d} N(0, 1)$.

依分布收敛等价于: $\lim_{n \rightarrow \infty} \Phi_n(t) = \Phi_Y(t)$.

只需证: $\frac{1}{\sqrt{n}} \sum_{k=1}^n Y_k$ 的特征函数 $\rightarrow e^{-\frac{t^2}{2}}$, $n \rightarrow \infty$.

由特征函数 $\xrightarrow{x \rightarrow \phi(x)}$, $\frac{1}{\sqrt{n}} \sum_{k=1}^n Y_k$ 特征函数为 $[\phi(\frac{t}{\sqrt{n}})]^n$. $\frac{t}{\sqrt{n}} \rightarrow 0$,

$\Phi(t) = E e^{itY_1} = \lim_{n \rightarrow \infty} \ln [\phi(\frac{t}{\sqrt{n}})]^n = \lim_{x \rightarrow 0} \frac{\ln [\phi(tx)]}{tx} \xrightarrow{\text{洛必达法则}} \frac{t^2}{2} \phi'(0)$.

$\Phi'(0) = t^2 \cdot EY^2 = -EY^2$ (二阶矩, 为 1) 则 $[\phi(\frac{t}{\sqrt{n}})]^n \rightarrow e^{-\frac{t^2}{2}}$.

· 连续性定理 (Continuity theorem) (最常用、最重要定理之一)

X_n 依分布收敛到 $X \Leftrightarrow \lim_{n \rightarrow \infty} \Phi_n(t) = \Phi(t), \forall t \in \mathbb{R}$.

(定义) 若在 $F(x)$ 的连续点 x , 有 $\lim_{n \rightarrow \infty} F_n(x) = F(x)$, 则称 X_n 依分布收敛到 X

(convergence in distribution), 或 $X_n \xrightarrow{d} X$; 或称 F_n 弱收敛到 F (weak convergence), 或 $F_n \xrightarrow{w} F$.

· 例 疫苗有效性问题 (更新) 接上页计算的 $n=5556$ 结果.

$M_n = (X_1 + \dots + X_n)/n$, 人群中疫苗有效比例设为 μ . 现在希望:

求适当的 n 以保证 $P(|M_n - \mu| < 0.03) \geq 0.95$. $\sigma = \sqrt{\text{Var}(X_i)}$,

$P = P\left(\left|\frac{M_n - \mu}{\sigma/\sqrt{n}}\right| < \frac{0.03}{\sigma/\sqrt{n}}\right) \approx P(|Z| < \frac{0.03\sqrt{n}}{\sigma}), \sigma \leq 1$, 且 $Z \sim N(0, 1)$,

则 $n = \left(\frac{1.96}{0.03}\right)^2 \approx 1068$ 即可. ($M_n \sim N(\mu, \frac{\sigma^2}{n})$) 用大数定律是宽泛适用范围,

中心极限可以近似拟合正态分布 ($n \rightarrow \infty$)

使用中心极限定理必须说明条件： iid 和方差有限。

Date. /

理论近似：当前 n 项和计算复杂或无显示表达时

例： $\{X_n\}$ iid, $X_i \sim U(-1, 1)$, $S_n = X_1 + X_2 + \dots + X_n$. 其密度函数

$$f_S(x) = \begin{cases} \frac{1}{2^n (n!)^{\frac{1}{2}}} \sum_{k=0}^{\lfloor \frac{n+x}{2} \rfloor} (-1)^k \binom{n}{k} (n+x-2k)^{n-1}, & |x| \leq n \\ 0, & |x| > n \end{cases}$$

$$\rightarrow S_n = nM_n \sim N(n\mu, n\sigma^2) \quad (\text{直接理解})$$

$$\text{修正近似: } S_n \approx N(n\mu, n\sigma^2) = N(0, \frac{1}{3}) \quad (\text{均匀分布 } \mu=0, \sigma^2=\frac{1}{3})$$

离散化修正：离散型随机变量上的应用

单点 \rightarrow 区域，区域两端扩展。以二项分布为例：

道理 (de Moivre-Laplace, CLT) 设 $S_n \sim B(n, p)$, n 充分大, $k, m \in \mathbb{N}$, 则

$$P(k \leq S_n \leq m) \approx \Phi\left(\frac{m-np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{k-np}{\sqrt{np(1-p)}}\right). \quad (\Phi \text{ 是标准正态 CDF})$$

$$\text{修正后为 } P(k \leq S_n \leq m) \approx \Phi\left(\frac{m+0.5-np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{k-0.5-np}{\sqrt{np(1-p)}}\right).$$

在计算单点概率时必须修正；其他情况下修正可以提高精度。

例 (建造电影院) 某地每日约有 $n=1600$ 人看电影，该地有一座旧电影院，预计建成后平均约有 $3/4$ 的观众将去新电影院。建设规划座位数时要求座位尽可能多，但“空座多于或等于 200”的概率不超过 10%。记座位数为 m 。

解：将每日看电影的观众按 $1 \sim 1600$ 排序, $X_i=1$ 表示去新电影院。 $P(X_i=1)=\frac{3}{4}$, $P(X_i=0)=\frac{1}{4}$.

$\{X_i\}$ 为 iid. 希望 $P\left(\sum_{i=1}^{1600} X_i \leq m-200\right) \leq 0.1$. 对 $\sum_{i=1}^{1600} X_i$ 用正态分布近似相当于

$$N(\mu n, \sigma^2 n) \Rightarrow N(1200, 1200) \Rightarrow \Phi\left(\frac{m-200+0.5-1200}{10\sqrt{3}}\right) = 0.1. \quad (\text{再用离散修正})$$

$$\Phi(1) = 0.1, x = -1.2816, m \approx 1377.$$

从实例中可见： $n \rightarrow \infty$ 时正态近似越精确。在实践中需要知道：样本量 n 多大时正态近似的结果可信。这依赖于 X_i 是否接近正态分布。特别地， X_i 是否对称。用正态近似计算 $P(S_n \leq c)$ 时，若 c 在 S_n 均值附近，其精度会更高。

二项分布的泊松估计与正态估计

泊松近似： $np = \lambda \Rightarrow B(n, p) \Rightarrow P(x) = X_1 + \dots + X_n, X_i \sim B(1, p), \{X_i\}$ iid.

条件： np 固定， $n \rightarrow \infty, p \rightarrow 0$.

正态近似： $B(n, p) = S_n \approx N(ES_n, \text{Var}(S_n)) = X_1 + \dots + X_n, X_i \sim B(1, p)$ iid.

条件: P 固定, $n \rightarrow \infty$. $S_n = X_1 + \dots + X_n \sim P(n)$, n 很大可直接正态近似.
 (对称) 若 nP 固定且很大, 比如 $X_i \sim P(1)$, $S_n \approx N(\mu S_n, \sigma^2 S_n)$.

例 $\{X_n\}$ i.i.d., $X_n \sim P(1)$. $S_n = \sum_{i=1}^n X_i$. 用 CLT 估计 $P(S_n = n)$. ($EY = \text{var} Y = \lambda$)

$$ES_n = n, \text{var}(S_n) = \sqrt{n}. P(S_n = n) \Rightarrow P(n - 0.5 \leq S_n \leq n + 0.5) \Rightarrow$$

$$= P\left(\frac{n - 0.5 - n}{\sqrt{n}} \leq \frac{S_n - n}{\sqrt{n}} \leq \frac{n + 0.5 - n}{\sqrt{n}}\right) = \Phi\left(\frac{-0.5}{\sqrt{n}}\right) - \Phi\left(\frac{0.5}{\sqrt{n}}\right) = 2\Phi\left(\frac{0.5}{\sqrt{n}}\right) - 1$$

$$\text{由此 } \frac{n^n}{n!} e^{-n} = P(S_n = n) \approx \int_{-\frac{1}{2\sqrt{n}}}^{\frac{1}{2\sqrt{n}}} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \approx \frac{1}{\sqrt{n}} \frac{1}{\sqrt{2\pi}}$$

得到 Stirling 公式: $n! \approx \sqrt{2\pi n} \left(\frac{n}{e}\right)^n$.

不是任意分布都可用中心极限定理, X_1, \dots, X_n 独立同分布且服从 Cauchy 分布,
 $M_n = \frac{1}{n}(X_1 + \dots + X_n)$. $\Phi_X(t) = e^{-|t|}$, 易证 $\Phi_{M_n}(t) = e^{-|t|}$, M_n 服从 Cauchy 分布.
 说明: 定理要求的“期望 μ 存在, 方差 $\sigma^2 < \infty$ ” 是必要条件.

收敛性总结 (依概率, 几乎处处, 依分布)

判断: 已知两个 r.v. X_1, X_2 同分布, 则 $X_1 = X_2$ (不一定正确)

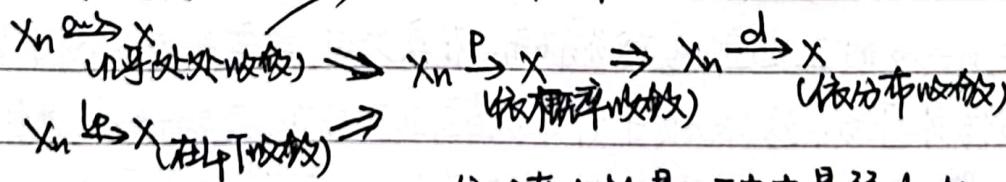
不妨令 X_1, X_2 表示抛硬币. $X_1 = \begin{cases} 0 & H \\ 1 & T \end{cases}, X_2 = \begin{cases} 0 & T \\ 1 & H \end{cases}$

$X_1(w=T)=1$ 而 $X_2(w=T)=0$, 则 X_1, X_2 依分布收敛, 但显然不是几乎处处收敛.
 也不是依概率收敛: 显然不满足 $P(|X_1 - X_2| \geq \varepsilon) \rightarrow 0$.

收敛模式补充: L_p 收敛 (不要求) 对 $p > 0$, 若 $\lim_{n \rightarrow \infty} E(|X_n - X|^p) = 0$,

则称 X_n 在 L_p 下收敛到 X , 记作 $X_n \xrightarrow{L_p} X$, 或 $X_n \rightarrow X$ in L_p . 例如 $\lim_{n \rightarrow \infty} E(|X_n - X|) = 0 \Leftrightarrow X_n \xrightarrow{L_1} X$.

各种收敛性之间关系: \rightarrow (又叫 n 次概率, 收敛)



依分布收敛是 4 种中最弱收敛.

依概率收敛得不到几乎处处收敛: $P(|X_n(w) - X(w)| > \varepsilon) \rightarrow 0$.

$$X(w) = 0, X_n(w) = \begin{cases} 1 & [0, \frac{1}{n}] \\ 0 & (\frac{1}{n}, 1] \end{cases} \dots \dots \dots$$

也得不到 L_1 收敛.

收敛性质补充：考虑两个随机变量序列 $\{X_i\}$ 和 $\{Y_i\}$, X_n, Y_n 分别依概率收敛， c 为已知常数，则有：

1° $cX_n, X_n + Y_n, \max\{0, X_n\}, |X_n|, X_n Y_n$ 都依概率收敛到各自极限。

2° 进一步，若 $Y_n \neq 0$, 则 X_n/Y_n 也依概率收敛到其对应极限。

几乎处处收敛和依概率收敛对细节有要求，但依分布收敛可互换细节，不影响整体当收敛到常数时依概率与依分布收敛等价。

(逆理) 连续映射定理 (Continuous mapping theorem) $\{X, X_n\}$ 是随机元序列, g 连续，则

1° $X_n \xrightarrow{a.s.} X \Rightarrow g(X_n) \xrightarrow{a.s.} g(X)$. 2° $X_n \xrightarrow{P} X \Rightarrow g(X_n) \xrightarrow{P} g(X)$.

3° $X_n \xrightarrow{d} X \Rightarrow g(X_n) \xrightarrow{d} g(X)$. (但是 $X_n \xrightarrow{L^p} X \Rightarrow g(X_n) \xrightarrow{L^p} g(X)$).

· Slutsky's theorem 设 $X_n \xrightarrow{d} X, Y_n \xrightarrow{d} c$, 则 (四则运算)

$X_n + Y_n \xrightarrow{d} X + c, X_n Y_n \xrightarrow{d} cX, X_n/Y_n \xrightarrow{d} X/c (c \neq 0)$.

连续性定理 Continuity theorem: X 的特征函数为 $\phi(t)$, X_n 的特征函数为 $\phi_{n,t}(t)$,

* 则 X_n 依分布收敛到 X 的充要条件是 $\lim_{n \rightarrow \infty} \phi_{n,t}(t) = \phi(t), \forall t \in \mathbb{R}$.

例: T 分布 $Z \sim N(0,1)$, $X \sim X_n^2$, X, Z 独立. 令 $T = \frac{Z}{\sqrt{X_n}}$, 则 $T \sim t_n$.

对 iid $Z_j \sim N(0,1)$, $X = Z_1^2 + \dots + Z_n^2$, $X \sim X_n^2$. 证明 $t_n \xrightarrow{d} t \sim N(0,1)$, $n \rightarrow \infty$:

(LLN) $\frac{1}{n} \sum_{i=1}^n Z_i^2 \xrightarrow{d} E Z^2 = 1$. (连续性定理) $\frac{1}{\sqrt{X_n}} \xrightarrow{d} 1$.

(Slutsky 定理) $X_n/Y_n \xrightarrow{d} X/1 \cdot c \Rightarrow t_n \xrightarrow{d} Z = N(0,1)$.

例 二项分布用泊松分布近似用连续性定理证明: (不需要特征函数, 可以

取较简单的概率母函数/矩母函数近似) 如下用概率母函数.

; $B(n, p)$, $p = \frac{\lambda}{n}$. $\lim_{n \rightarrow \infty} \left[\frac{1}{n} \sum_{k=0}^n (1-p)^k p^{n-k} \right] = \lim_{n \rightarrow \infty} (1 - \frac{\lambda}{n})^n p^{n-\lambda} = \lim_{n \rightarrow \infty} \left[(1 - \frac{\lambda}{n})^{\frac{n}{\lambda}} \right]^{\lambda} = e^{-\lambda} \cdot \lambda^n p^n = e^{-\lambda} \lambda^\lambda$.